




NICOLAS PETIT | 25/09/2025 | OPENCLASSROOMS

PROJET 10

— 2025 —

METTRE EN PLACE UN PIPELINE
D'ORCHESTRATION DES FLUX

Sommaire

1 CONTEXTE

3 KESTRA

5 POINTS DE VIGILANCE

2 DEMARCHE TECHNIQUE

4 JUSTIFICATION DES CHOIX

6 CONCLUSION

CONTEXTE

BOTTLENECK



CONTEXTE

CONTEXTE DU PROJET

L'entreprise BottleNeck, marchand de vin, souhaite automatiser sa chaîne de traitement et d'analyse de données.

Le but de la mission est de mettre en place un processus permettant de générer de manière mensuelle, les indicateurs suivants :

- les rapports de chiffre d'affaires,
- les extractions distinguant vins premium et vins ordinaires.

Pour cela, il fallait s'appuyer sur le travail initial de Stéphane, Data Analyst, qui a déjà :

1. nettoyé les données issues des systèmes CMS et ERP,
2. réconcilié ces données pour calculer le chiffre d'affaires,
3. identifié les vins premium à l'aide de méthodes statistiques.

La mission consiste donc à industrialiser et fiabiliser ce processus afin d'obtenir des résultats réguliers et automatisés.

DEMARCHE TECHNIQUE

Démarche Technique

Outils : Docker, Kestra, Draw.io
Langages : Yaml, Python, SQL

Cette démarche technique va suivre 4 axes principaux :

- Source de données
- Préparation et intégration
- Pipeline automatisé
- Exportation des résultats et analyse

1. Les sources de données sont 3 fichiers xlsx :

- erp.xlsx
- web.xlsx
- liaison.xlsx


2. Nettoyage des données du fichier web pour gérer les lignes vides et consolidation des données via liaison.xlsx

3. Mise en place du pipeline automatisé via Kestra, avec un fichier YAML, comprenant du python et du SQL et automatisation avec un cronjob.

4. Détection des incohérences de stock, liste de vins premiums et ordinaires et calcul du CA par produit et total.

Démarche Technique

Diagramme de flux



KESTRA

KESTRA

Kestra : outil d'orchestration de workflows

KESTRA

Kestra est un outil open source d'orchestration de workflows. Il permet d'automatiser et de planifier des pipelines de données ou d'autres traitements.

Voici ces 3 caractéristiques principales, utiles dans ce contexte :


- Interface utilisateur plus moderne que la plupart des autres solutions similaires.
- Les workflows sont en YAML ce qui simplifie fortement la mise en œuvre d'un pipeline.
- Interface graphique permettant de suivre les exécutions, avec des logs d'erreurs détaillés et des fichiers de sortie, directement téléchargeables depuis l'interface

Mise en place avec Docker, directement avec un environnement éphémère via cette commande :

```
nicolas.petit@humans.local@HCKL062:~/Documents/Data_Engineering/Projet_10 $ docker run --pull=always --rm -it -p 8005:8080 --user root \
-v /var/run/docker.sock:/var/run/docker.sock \
-v /tmp:/tmp \
-v /tmp/kestra_db:/tmp/kestra_db \
kestra/kestra:latest server local
```

KESTRA

Pour mettre en place le pipeline de données, un script YAML a été conçu.
Ce script contient du Python, du SQL et le cronjob.



JUSTIFICATION DES CHOIX

JUSTIFICATION DES CHOIX

JUSTIFICATION DES CHOIX

Pourquoi ces technologies utilisées dans le cadre de ce projet
BottleNeck :

- Kestra avec Docker
 - Orchestration et automatisation de workflow
 - Docker pour le déploiement et la rapidité de mise en place de l'instance
- Script YAML
 - Maintenance facile du script
 - Syntaxe lisible
- Python
 - Grand nombre de paquets utilisés en data engineering
 - Intégration simple dans le script YAML général
- SQL
 - Optimisé pour le calcul du chiffre d'affaires
 - Assure des traitements performants
- Cronjob
 - Outil simple et robuste pour la récurrence
 - Permet de mettre en place l'automatisation du pipeline directement depuis le script YAML

POINTS DE VIGILANCE

POINTS DE VIGILANCE

POINTS DE VIGILANCE

L'analyse effectuée à permis de coller aux statistiques émises par Stéphane, le Data Analyst. Cependant, pendant la réalisation de la mission, certains points méritent d'être mis en lumière.

Le premier point concerne les listes de vins. Dans le catalogue produit de BottleNeck, certains produits ne sont pas des vins mais, du champagne ou des spiritueux par exemple. Ces produits peuvent fausser le z-score et c'est un point important à mettre en lumière.

Le second point concerne les incohérences de stock. Ce point concerne 8 lignes sur le fichier du ERP. 3 différents cas sont représentés :

- Stock négatif
- Stock égal à 0 indiqué instock
- Stock supérieur à 0 indiqué outofstock

product_id	onsale_web	price	stock_quantity	stock_status
4055	0	86.1	1	outofstock
4090	0	73.0	6	outofstock
4092	0	47.0	6	outofstock
4954	1	25.0	0	instock
4973	0	10.0	-1	outofstock
5700	1	44.5	-1	outofstock
5826	1	41.2	12	outofstock
6125	0	14.2	48	outofstock

CONCLUSION